고객을 세그먼테이션하자 [프로젝트]

11-2. 데이터 불러오기

데이터 살펴보기

(사전 자료 파악) <u>https://www.kaggle.com/datasets/carrie1/ecommerce-data</u> data.csv 데이터 특징

컬럼명	설명
InvoiceNo	각각의 고유한 거래를 나타내는 코드.이 코드가 'C'라는 글자로 시작한다면, 취소를 나타냄하나의 거래에 여러 개의 제품이 함께 구매되었다면, 1개의 InvoiceNo에는 여러 개의 StockCode가연결되어 있음
StockCode	각각의 제품에 할당된 고유 코드
Description	각 제품에 대한 설명
Quantity	거래에서 제품을 몇 개 구매했는지에 대한 단위 수 (참고: - 값은 판매나 반품을 의미)
InvoiceDate	거래가 일어난 날짜와 시간
UnitPrice	제품 당 단위 가격(영국 파운드)
CustomerID	각 고객에게 할당된 고유 식별자 코드
Country	주문이 발생한 국가

• 테이블에 있는 10개의 행만 출력하기

```
SELECT * FROM modulabs_project.data LIMIT 10;
```

[결과]

Row	InvoiceNo *	StockCode *	Description *	Quantity *	InvoiceDate *	UnitPrice ▼	CustomerID -	Country *
1	536414	22139	null	56	2010-12-01 11:52:00 UTC	0.0	null	United Kingdom
2	536545	21134	null	1	2010-12-01 14:32:00 UTC	0.0	nuli	United Kingdom
3	536546	22145	null	1	2010-12-01 14:33:00 UTC	0.0	nuli	United Kingdom
4	536547	37509	null	1	2010-12-01 14:33:00 UTC	0.0	null	United Kingdom
5	536549	85226A	null	1	2010-12-01 14:34:00 UTC	0.0	null	United Kingdom
6	536550	85044	null	1	2010-12-01 14:34:00 UTC	0.0	Run	United Kingdom
7	536552	20950	null	1	2010-12-01 14:34:00 UTC	0.0	null	United Kingdom
8	536553	37461	null	3	2010-12-01 14:35:00 UTC	0.0	null	United Kingdom
9	536554	84670	null	23	2010-12-01 14:35:00 UTC	0.0	nuli	United Kingdom
10	536589	21777	nuli	-10	2010-12-01 16:50:00 UTC	0.0	null	United Kingdom

• 전체 데이터는 몇 행으로 구성되어 있는지 확인하기

```
SELECT COUNT(*) FROM modulabs_project.data
```

[결과]



541,909 행으로 구성되어 있음

데이터 수 세기

• COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기

```
-- SELECT COUNT(*), COUNT(InvoiceNo), COUNT(StockCode), COUNT(Description), COUNT(Quantity), COUNT(In SELECT COUNT(*) AS total_rows, COUNT(InvoiceNo) AS InvoiceNo_count, COUNT(StockCode) AS StockCode_cou COUNT(Description) AS Description_count, COUNT(Quantity) AS Quantity_count, COUNT(InvoiceDate) AS InvoiceDate_count, COUNT(UnitPrice) AS UnitPrice_count, COUNT(CustomerID) AS CustomerID_count, COUNT(Country) AS Country_count FROM `modulabs_project.data`;
```

```
| Riow | total_rows * | InvoiceNo.count * | StockCode_count * | Description_count * | Quantity_count * | InvoiceNote_count * | UniPrice_count * CustomeriD_count * Country_count * | CustomeriD_count * | CustomeriD_count
```

11-4. 데이터 전처리 방법(1): 결측치 제거


컬럼 별 누락된 값의 비율 계산

- 각 컬럼 별 누락된 값의 비율을 계산
 - \circ 각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

```
-- SELECT 'InvoiceNo' AS column_name, COUNT(*) - COUNT(InvoiceNo) AS missing_values FROM modulabs_pr
-- UNION ALL
-- SELECT 'StockCode' AS column_name, COUNT(*) - COUNT(StockCode) AS missing_values FROM modulabs_pr
-- UNION ALL
-- SELECT 'Description' AS column_name, COUNT(*) - COUNT(Description) AS missing_values FROM modulab
-- UNION ALL
-- SELECT 'Quantity' AS column_name, COUNT(*) - COUNT(Quantity) AS missing_values FROM modulabs_proj
-- UNION ALL
-- SELECT 'InvoiceDate' AS column_name, COUNT(*) - COUNT(InvoiceDate) AS missing_values FROM modulab
-- UNION ALL
-- SELECT 'UnitPrice' AS column_name, COUNT(*) - COUNT(UnitPrice) AS missing_values FROM modulabs_pr
-- UNION ALL
-- SELECT 'CustomerID' AS column_name, COUNT(*) - COUNT(CustomerID) AS missing_values FROM modulabs_
-- UNION ALL
-- SELECT 'Country' AS column_name, COUNT(*) - COUNT(Country) AS missing_values FROM modulabs_projec
```

```
SELECT column_name,
  ROUND((total - column_value) / total * 100, 2) AS missing_percentage
FROM (
 SELECT
   CASE
     WHEN column name = 'InvoiceNo' THEN COUNT(InvoiceNo)
     WHEN column_name = 'StockCode' THEN COUNT(StockCode)
     WHEN column_name = 'Description' THEN COUNT(Description)
     WHEN column_name = 'Quantity' THEN COUNT(Quantity)
     WHEN column_name = 'InvoiceDate' THEN COUNT(InvoiceDate)
     WHEN column_name = 'UnitPrice' THEN COUNT(UnitPrice)
     WHEN column_name = 'CustomerID' THEN COUNT(CustomerID)
     WHEN column_name = 'Country' THEN COUNT(Country)
    END AS column_value,
    COUNT(*) AS total,
    CASE
     WHEN column_name = 'InvoiceNo' THEN 'InvoiceNo'
     WHEN column_name = 'StockCode' THEN 'StockCode'
     WHEN column_name = 'Description' THEN 'Description'
     WHEN column_name = 'Quantity' THEN 'Quantity'
     WHEN column_name = 'InvoiceDate' THEN 'InvoiceDate'
     WHEN column_name = 'UnitPrice' THEN 'UnitPrice'
     WHEN column_name = 'CustomerID' THEN 'CustomerID'
     WHEN column_name = 'Country' THEN 'Country'
   END AS column name
 FROM modulabs_project.data
  GROUP BY column_name
) AS column_data;
```

[결과]



결측치 처리 전략

• StockCode = '85123A' 의 Description 을 추출하는 쿼리문을 작성하기

```
SELECT Description
FROM modulabs_project.data
WHERE StockCode = '85123A';
```

[결과]



(이하 결과 생략)

결측치 처리

• DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시

```
-- CustomerID 또는 Description이 NULL인 데이터를 삭제 (결측치 처리해야 하므로)
DELETE FROM modulabs_project.data
WHERE CustomerID IS NULL OR Description IS NULL;
SELECT COUNT(*) FROM modulabs_project.data;
```

[결과]



11-5. 데이터 전처리(2): 중복값 처리

컬럼 별 누락된 값의 비율 계산

• 각 컬럼 별 누락된 값의 비율을 계산

○ 각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

```
WITH TotalRows AS (
 SELECT COUNT(*) AS total_rows FROM modulabs_project.data
)
SELECT
  'InvoiceNo' AS column_name,
  (COUNT(*) - COUNT(InvoiceNo)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
  'StockCode' AS column_name,
  (COUNT(*) - COUNT(StockCode)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
  'Description' AS column_name,
  (COUNT(*) - COUNT(Description)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
  'Quantity' AS column_name,
  (COUNT(*) - COUNT(Quantity)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
 'InvoiceDate' AS column_name,
  (COUNT(*) - COUNT(InvoiceDate)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
  'UnitPrice' AS column_name,
  (COUNT(*) - COUNT(UnitPrice)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
  'CustomerID' AS column_name,
  (COUNT(*) - COUNT(CustomerID)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data
UNION ALL
SELECT
  'Country' AS column_name,
  (COUNT(*) - COUNT(Country)) / (SELECT total_rows FROM TotalRows) * 100 AS missing_percentage
FROM modulabs_project.data;
```

[결과 이미지]

Row	column_name ▼	missing_percentage
1	UnitPrice	0.0
2	CustomerID	0.0
3	Quantity	0.0
4	Country	0.0
5	StockCode	0.0
6	Description	0.0
7	InvoiceDate	0.0
8	InvoiceNo	0.0

중복값 확인

- 중복된 행의 수를 세어보기
 - \circ 8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기

```
SELECT *, COUNT(*) AS duplicate_count
FROM modulabs_project.data
GROUP BY InvoiceNo, StockCode, Description, Quantity,
InvoiceDate, UnitPrice, CustomerID, Country
HAVING COUNT(*) > 1;
```

[결과]


Row	InvoiceNo •	StockCode *	Description •	Quantity *	InvoiceDate •	UnitPrice •	CustomerID •	Country •	duplicate_count *
1	557305	22645	CERAMIC HEART FAIRY CAKE	4	2011-06-19 14:42:00 UTC	1.45	13568	United Kingdom	2
2	569943	20972	PINK CREAM FELT CRAFT TRI	1	2011-10-05 18:08:00 UTC	1.25	14592	United Kingdom	2
3	571241	22630	DOLLY GIRL LUNCH BOX	1	2011-10-14 14:58:00 UTC	1.95	14592	United Kingdom	2
4	571241	72816	SET/3 CHRISTMAS DECOUPAG	1	2011-10-14 14:58:00 UTC	0.95	14592	United Kingdom	2
5	571241	22095	LADS ONLY TISSUE BOX	3	2011-10-14 14:58:00 UTC	0.39	14592	United Kingdom	2
6	571241	22940	FELTCRAFT CHRISTMAS FAIRY	1	2011-10-14 14:58:00 UTC	4.25	14592	United Kingdom	2
7	571241	22807	SET OF 6 T-LIGHTS TOADSTOO	1	2011-10-14 14:58:00 UTC	2.95	14592	United Kingdom	2
8	554917	22849	BREAD BIN DINER STYLE MINT	1	2011-05-27 12:29:00 UTC	16.95	15104	United Kingdom	2

중복값 처리

- 중복값을 제거하는 쿼리문 작성하기
 - CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트

```
CREATE OR REPLACE TABLE modulabs_project.data AS
SELECT DISTINCT *
FROM modulabs_project.data;
```

[결과]



11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

• 고유(unique)한 InvoiceNo 의 개수를 출력하기


```
{\tt SELECT~COUNT(DISTINCT~InvoiceNo)~AS~unique\_invoice\_count} \\ {\tt FROM~modulabs\_project.data};
```

[결과]




• 고유한 InvoiceNo 를 앞에서부터 100개를 출력하기

SELECT DISTINCT InvoiceNo AS unique_invoice_count FROM modulabs_project.data LIMIT 100;




•••



• InvoiceNo 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

```
SELECT *
FROM modulabs_project.data
WHERE InvoiceNo LIKE 'C%'
LIMIT 100;
```



• 구매 건 상태가 Canceled 인 데이터의 비율(%) - 소수점 첫번째 자리까지

SELECT ROUND(SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) / COUNT(*) * 100, 1) AS canceled_p FROM modulabs_project.data;

[결과]


Row	canceled_percentage
1	2.2

StockCode 살펴보기

• 고유한 StockCode 의 개수를 출력하기

```
SELECT COUNT(DISTINCT StockCode) AS unique_stockcode_count FROM modulabs_project.data;
```

[결과]



- 어떤 제품이 가장 많이 판매되었는지 보기 위하여 StockCode 별 등장 빈도를 출력하기
 - 。 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_count
FROM modulabs_project.data
GROUP BY StockCode
ORDER BY sell_count DESC
LIMIT 10;
```

[결과]

Row	StockCode ▼	sell_count ▼
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409
5	84879	1405
6	20725	1346
7	22720	1224
8	POST	1196
9	22197	1110
10	23203	1108

- StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - 。 **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
   SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
   FROM modulabs_project.data
)
WHERE number_count <= 1;</pre>
```

Row	StockCode ▼	number_count ▼
1	POST	0
2	М	0
3	PADS	0
4	D	0
5	BANK CHARGES	0
6	DOT	0
7	CRUK	0
8	C2	1

Tip. LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')): StockCode 의 전체 길이에서 숫자를 제거한 후의 길이를 뺌으로써 숫자의 개수를 계산

- StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
SELECT
    ROUND(COUNT(*) * 100.0 / (SELECT COUNT(*) FROM modulabs_project.data), 2) AS percentage
FROM (
    SELECT StockCode,
        LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
    FROM modulabs_project.data
) AS subquery
WHERE number_count <= 1;</pre>
```

[결과]



• 제품과 관련되지 않은 거래 기록을 제거하기

```
DELETE FROM modulabs_project.data
WHERE StockCode IN (
    SELECT DISTINCT StockCode
FROM (
    SELECT StockCode
    FROM (
        SELECT StockCode,
        LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
        FROM modulabs_project.data
        )
WHERE number_count <= 1
    )
)</pre>
```

[결과]

This statement removed 1,915 rows from data.

Description 살펴보기

• 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기

```
SELECT Description, COUNT(*) AS description_cnt
FROM modulabs_project.data
GROUP BY Description ORDER BY description_cnt DESC LIMIT 30;
```


[결과]



• 서비스 관련 정보를 포함하는 행들을 제거하기



• 대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기



UnitPrice 살펴보기

• UnitPrice 의 최솟값, 최댓값, 평균을 구하기

 ${\tt SELECT\ MIN(UnitPrice)\ AS\ min_price,\ MAX(UnitPrice)\ AS\ max_price,\ AVG(UnitPrice)\ AS\ avg_price} \\ {\tt FROM\ modulabs_project.data;}$

[결과]



• 단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기

SELECT COUNT(*) AS cnt_quantity, MIN(Quantity) AS min_quantity, MAX(Quantity) AS max_quantity, AVG(Q FROM modulabs_project.data
WHERE UnitPrice = 0;

[결과]



• UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기



11-7. RFM 스코어

RFM 스코어 복습

- Recency: 고객이 마지막으로 구매한 시점. 최근에 구매한 고객들은 더 자주 구매할 가능성이 높기 때문에, 최신성 점수가 높은지를 고려
- Frequency: 특정 기간 동안 고객이 얼마나 자주 우리의 제품이나 서비스를 구매하는지. 빈번하게 구매하는 고객은 충성도가 높은 고객일 확률이 높기 때문에, 빈도 점수가 높은지를 고려
- Monetary: 고객이 지출한 총 금액. 많은 금액을 지불한 고객일수록 더 가치가 높은 충성 고객일 수 있음. 앞으로도 우리의 제품과 사이트에 많은 돈을 지불할 수 있는 고객이므로, 가치 점수가 높은지를 함께 고려

Recency

• InvoiceDate 컬럼을 연월일 자료형으로 변경하기

```
SELECT DATE(InvoiceDate) AS InvoiceDay, *
FROM modulabs_project.data;
```

[결과]

Row	InvoiceDay *	InvoiceNo *	StockCode *	Quantity *	InvoiceDate ▼	UnitPrice ▼	OustomerID *	Country *	Description *
1	2011-11-03	574301	23240	6	2011-11-03 16:15:00 UTC	4.15	12544	Spain	SET OF 4 KNICK KNACK TINS
2	2011-11-03	574301	23511		2011-11-03 16:15:00 UTC	2.08	12544	Spain	EMBROIDERED RIBBON REEL E
3	2011-11-03	574301	20971	12	2011-11-03 16:15:00 UTC	1.25	12544	Spain	PINK BLUE FELT CRAFT TRINK
4	2011-11-03	574901	85049A	12	2011-11-03 16:15:00 UTC	1.25	12544	Spain	TRADITIONAL CHRISTMAS RIB
5	2011-11-03	574301	22621	12	2011-11-03 16:15:00 UTC	1.65	12544	Spain	TRADITIONAL KNITTING NANCY
6	2011-11-03	574901	23514	6	2011-11-03 16:15:00 UTC	2.08	12544	Spain	EMBROIDERED RIBBON REEL S

• 가장 최근 구매 일자를 MAX() 함수로 찾아보기

```
SELECT DATE(MAX(InvoiceDate)) AS most_recent_date,
FROM modulabs_project.data;
```

[결과]



• 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기

```
SELECT
CustomerID,
MAX(CAST(InvoiceDate AS DATE)) AS InvoiceDay
FROM modulabs_project.data
GROUP BY CustomerID;
```

[결과]

• 가장 최근 일자(most_recent_date)와 유저별 마지막 구매일(InvoiceDay)간의 차이를 계산하기

```
SELECT
CustomerID,
EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
SELECT
CustomerID,
MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM modulabs_project.data
GROUP BY CustomerID
);
```

[결과]

```
| AN INCOME | MILES | OUT | OU
```

- 최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 user_r 이라는 이름의 테이블로 저장하기
 - TIPS: 쿼리문에서 EXTRACT 함수의 사용 방법
 - MAX(InvoiceDay) over () InvoiceDay : 각 고객(CustomerID)의 각 구매일(InvoiceDay)과 전체 데이터셋에서의 마지막 구매일 (MAX(InvoiceDay)) 간의 차이를 계산
 - EXTRACT (DAY FROM ...): 여기에서 EXTRACT 함수는 위에서 계산된 날짜 차이에서 일(DAY) 부분만을 추출. 즉 각 고객의 최근 구매일로부터 해당 구매 건의 구매일부터의 날짜 차이를 계산하는 함수

```
CREATE OR REPLACE TABLE modulabs_project.user_r AS
SELECT
CustomerID,
EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
SELECT
CustomerID,
MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM modulabs_project.data
GROUP BY CustomerID
);
[결과]
```

JOB INFORMATION RESULTS EXECUTION DETAILS EXECUTION GRAPH

This statement created a new table named user_r.

Frequency

[결과]

• 고객마다 고유한 InvoiceNo의 수를 세어보기

```
SELECT
CustomerID,
COUNT(DISTINCT InvoiceNo) AS purchase_cnt
FROM modulabs_project.data
GROUP BY CustomerID;
```

• 각 고객 별로 구매한 아이템의 총 수량 더하기

```
SELECT
CustomerID,
SUM(Quantity) AS item_cnt
FROM modulabs_project.data
GROUP BY CustomerID;
```


[결과]

• 전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 user_rf 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE modulabs_project.user_rf AS
-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
 SELECT
   CustomerID,
   COUNT(DISTINCT InvoiceNo) AS purchase_cnt
 FROM modulabs_project.data
 GROUP BY CustomerID
),
-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
 SELECT
   CustomerID,
   SUM(Quantity) AS item_cnt
 FROM modulabs_project.data
 GROUP BY CustomerID
)
-- 기존의 user_r에 (1)과 (2)를 통합
 pc.CustomerID,
 pc.purchase_cnt,
 ic.item_cnt,
 ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
 ON pc.CustomerID = ic.CustomerID
JOIN modulabs_project.user_r AS ur
 ON pc.CustomerID = ur.CustomerID;
```

[결과]





Monetary

• 고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)

```
SELECT
CustomerID,
ROUND(SUM(UnitPrice * Quantity), 1) AS user_total
FROM modulabs_project.data
GROUP BY CustomerID;

[결과]
```



- 고객별 평균 거래 금액 계산
 - 고객별 평균 거래 금액을 구하기 위해 1) data 테이블을 user_rf 테이블과 조인(LEFT JOIN) 한 후, 2) purchase_cnt 로 나누어서 3) user_rfm 테이블로 저장하기


```
CREATE OR REPLACE TABLE modulabs_project.user_rfm AS
SELECT
 rf.CustomerID AS CustomerID,
 rf.purchase_cnt,
 rf.item_cnt,
 rf.recency,
 ut.user_total,
 ROUND(ut.user_total / rf.purchase_cnt, 1) AS user_average
FROM modulabs_project.user_rf rf
LEFT JOIN (
 -- 고객 별 총 지출액
 SELECT
   CustomerID,
   ROUND(SUM(UnitPrice * Quantity), 1) AS user_total
 FROM modulabs_project.data
 GROUP BY CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;
```

[결과]

```
JOB INFORMATION MISSISS EXECUTION DETAILS EXECUTION GRAPH

This statement created a new table named user of in.

COTO MALE
```



RFM 통합 테이블 출력하기

• 최종 user_rfm 테이블을 출력하기

```
SELECT *
FROM modulabs_project.user_rfm;
[결과]
```



11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

1) 고객 별로 구매한 상품들의 고유한 수를 계산하기 2)
 user_rfm 테이블과 결과를 합치기 3)
 user_data 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH unique_products AS (
    SELECT
        CustomerID,
        COUNT(DISTINCT StockCode) AS unique_products
    FROM modulabs_project.data
        GROUP BY CustomerID
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM modulabs_project.user_rfm AS ur
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

[결과]

```
DOS DEFORMATION DESIGNATION DESIGNATION DESIGNATION DEFORMS DESCRIPTION GRAPH

■ This statement created a new table numed user_data. ■ COTO TABLE


© TOTO TABLE
```

2. 평균 구매 주기

- 고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)
 - 균 구매 소요 일수를 계산하고, 그 결과를 user_data 에 통합

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
 SELECT
   CustomerID,
   CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_inte
   -- (1) 구매와 구매 사이에 소요된 일수
   SELECT
     CustomerID,
     DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY)
     modulabs_project.data
   WHERE CustomerID IS NOT NULL
  GROUP BY CustomerID
)
SELECT u.*, pi.* EXCEPT (CustomerID)
FROM modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

[결과]



3. 구매 취소 경향성

• 고객의 취소 패턴 파악하기

1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수

2) 취소 비율(cancel_rate): 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율

 취소 빈도와 취소 비율을 계산하고 그 결과를 user_data 에 통합하기 (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE bright-meridian-439401-g6.modulabs_project1.user_data AS


WITH TransactionInfo AS (
    SELECT
        CustomerID,
        COUNT(InvoiceNo) AS total_transactions,
        SUM(CASE WHEN stockcode LIKE 'C%'THEN 1 ELSE 0 END) AS cancel_frequency
        FROM bright-meridian-439401-g6.modulabs_project1.data
        GROUP BY customerID
)

SELECT u.*, t.* EXCEPT(CustomerID),
        ROUND(cancel_frequency * 100.0 / total_transactions, 2)
        AS cancel_rate

FROM bright-meridian-439401-g6.modulabs_project1.user_data AS u

LEFT JOIN TransactionInfo AS t
ON U.customerID = t.customerID
```

[결과]



• 다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 user_data 를 출력하기

```
SELECT * FROM modulabs_project.user_data
```

[결과]

```
Row Customerill • purchase_cnt • Rem_cnt • recency • cose_folal • user_wespe • unique_recolucis • reverspe_interval • total_transactions • cancel_frequency • cancel_
```

회고

하루에 완수하기 다수 버거웠으나, 지금까지 배운 SQL과 빅쿼리, 그리고 고객 데이터 분석을 익히는데 많은 도움이 되었습니다.